

**Nama : Raihana Fawaz**

**NIM : 1103210102**

**Kelas : TK-45-05**

### **Analisis CNN Cifar Dataset 10**

CIFAR-10 adalah dataset standar dalam bidang pembelajaran mesin dan visi komputer, yang sering digunakan untuk melatih dan menguji model pengenalan gambar. Berikut adalah karakteristik utama dari CIFAR-10:

1. Isi Dataset: CIFAR-10 terdiri dari 60.000 gambar berwarna dengan resolusi rendah (32x32 piksel). Dataset ini terbagi menjadi 10 kelas yang berbeda, yaitu pesawat terbang (airplane), mobil (automobile), burung (bird), kucing (cat), rusa (deer), anjing (dog), katak (frog), kuda (horse), kapal (ship), dan truk (truck).
2. Pembagian Dataset: Dataset terbagi menjadi 50.000 gambar untuk pelatihan dan 10.000 gambar untuk pengujian. Gambar dalam dataset ini sudah di-normalisasi dan diberi label, sehingga siap digunakan untuk berbagai tugas klasifikasi.
3. Tujuan Penggunaan: CIFAR-10 dirancang untuk mengevaluasi model pengenalan gambar pada masalah klasifikasi multi-kelas dengan data yang sederhana namun menantang karena resolusi gambar yang kecil dan tingkat kompleksitas yang cukup tinggi dalam fitur visual.

#### **Berikut penjelasan pada proses yang digunakan:**

1. Kernel Size: Membandingkan ukuran kernel (3x3, 5x5, 7x7) untuk menentukan pengaruh terhadap kemampuan ekstraksi fitur dari data input.
2. Pooling: Menguji performa MaxPooling dan AvgPooling untuk mengevaluasi dampaknya pada pengurangan dimensi fitur sambil mempertahankan informasi penting.
3. Epoch: Membandingkan jumlah epoch (5, 50, 100, 250, 350) untuk menganalisis pengaruh durasi pelatihan terhadap akurasi model dengan bantuan callback seperti Early Stopper dan Learning Rate Scheduler.
4. Optimizer: Menggunakan berbagai algoritma optimasi (SGD, RMSProp, Adam) untuk mengevaluasi efisiensi konvergensi dan performa model selama pelatihan.

### **Hyperparameter dan output:**

Pada eksperimen dengan kernel size (3x3, 5x5, 7x7), ukuran kernel memengaruhi kemampuan model dalam menangkap detail pada gambar. Kernel yang lebih kecil (3x3) memberikan performa yang lebih stabil dibandingkan kernel lebih besar, meskipun kernel besar dapat menangkap lebih banyak fitur pada resolusi rendah. Pooling dibandingkan antara MaxPooling dan AvgPooling, di mana MaxPooling sering menghasilkan performa lebih baik dengan menyoroti fitur dominan, sementara AvgPooling cenderung mempertahankan lebih banyak informasi rata-rata, yang kadang-kadang mengurangi kemampuan generalisasi.

Dalam hal jumlah epoch (5, 50, 100, 250, 350), peningkatan jumlah epoch memperbaiki akurasi hingga batas tertentu sebelum overfitting terjadi, yang ditangani dengan mekanisme early stopping. Early stopping terbukti efektif dalam menghentikan pelatihan saat validasi loss tidak menunjukkan perbaikan signifikan, sementara learning rate scheduler membantu mengoptimalkan konvergensi dengan menyesuaikan kecepatan belajar. Akhirnya, pada perbandingan optimizer (SGD, RMSProp, Adam), Adam menunjukkan konvergensi cepat dan akurasi yang lebih tinggi dibanding SGD dan RMSProp, terutama dalam eksperimen dengan epoch terbatas, karena kemampuannya untuk menyesuaikan learning rate secara adaptif untuk setiap parameter.

### **Berikut analisis output dari eksperimen berdasarkan file yang diberikan:**

#### **1. Kernel Size:**

Kernel 3x3 menunjukkan performa lebih baik dibanding kernel 5x5 dan 7x7, dengan loss dan akurasi validasi yang lebih stabil. Kernel yang lebih kecil efektif menangkap detail pada resolusi rendah, seperti pada CIFAR-10, sementara kernel besar cenderung menangkap informasi global yang bisa berlebihan untuk dataset ini.

#### **2. Pooling:**

MaxPooling unggul dibandingkan AvgPooling, terutama pada model dengan epoch terbatas. MaxPooling membantu menyoroti fitur dominan yang lebih relevan untuk klasifikasi, sedangkan AvgPooling menghasilkan akurasi lebih rendah karena informasi rata-rata tidak cukup mewakili karakteristik utama pada gambar CIFAR-10.

#### **3. Epoch:**

Model menunjukkan peningkatan akurasi hingga sekitar 100-250 epoch, setelah itu overfitting terjadi, dengan validasi loss mulai naik meskipun training loss terus turun. Early stopping terbukti efektif dalam mencegah overfitting, terutama pada konfigurasi dengan 250 dan 350 epoch, menghentikan pelatihan lebih awal dan menghemat waktu komputasi.

#### **4. Optimizer:**

Adam secara konsisten mengungguli SGD dan RMSProp dalam hal akurasi dan kecepatan konvergensi. Learning rate adaptif yang dimiliki Adam membantu model dengan cepat mencapai performa optimal, terutama pada eksperimen dengan jumlah epoch yang lebih sedikit. Sementara itu, SGD mengalami konvergensi yang lebih lambat tetapi mampu mencapai akurasi yang kompetitif dengan jumlah epoch yang lebih banyak, sehingga cocok untuk pelatihan dalam jangka waktu yang lebih panjang.

#### 5. Overall Accuracy:

Akurasi tertinggi (~73%) tercapai dengan kombinasi kernel 3x3, MaxPooling, Adam optimizer, dan 100-250 epoch. Hal ini menunjukkan bahwa konfigurasi ini optimal untuk menangani resolusi rendah dan variasi kompleksitas CIFAR-10.

#### **Hyperparameter terbaik:**

- Kernel Size: 3x3 memberikan hasil terbaik karena mampu menangkap detail lokal pada gambar CIFAR-10, menghasilkan akurasi yang lebih tinggi dan validasi loss yang lebih rendah dibanding kernel lainnya.
- Pooling: MaxPooling lebih unggul karena lebih fokus pada fitur dominan, yang penting untuk klasifikasi, dibandingkan AvgPooling yang cenderung mempertahankan informasi rata-rata.
- Optimizer: Adam memberikan performa terbaik dalam hal kecepatan konvergensi dan akurasi akhir, terutama pada jumlah epoch rendah hingga menengah (50–250), karena mekanisme adaptifnya.
- Epoch: 100–250 epoch memberikan keseimbangan terbaik antara akurasi tinggi dan overfitting. Validasi loss mencapai titik stabil di rentang ini sebelum mulai naik pada epoch lebih besar.

#### **Hyperparameter Terburuk:**

- Kernel Size: 7x7 menunjukkan performa terburuk karena terlalu besar untuk dataset beresolusi rendah seperti CIFAR-10, menghasilkan model yang overfit dan akurasi lebih rendah.
- Pooling: AvgPooling berkinerja lebih buruk karena kehilangan detail penting dalam fitur dominan, yang mengurangi akurasi akhir.
- Optimizer: SGD menunjukkan performa terendah, terutama pada epoch rendah, karena membutuhkan lebih banyak iterasi untuk mencapai konvergensi.
- Epoch: 5 epoch menghasilkan model yang underfit, dengan akurasi yang rendah dan validasi loss yang tinggi, menunjukkan bahwa model belum memiliki cukup waktu untuk belajar.

Kesimpulan:

Kombinasi kernel size 3x3, MaxPooling, Adam optimizer, dan 100–250 epoch adalah konfigurasi hyperparameter terbaik, sementara kernel size 7x7, AvgPooling, SGD, dan 5 epoch adalah konfigurasi terburuk.